

SPLIT

Relatório da Feature de Inteligência Artificial

Assistente inteligente de despesas • validação realizada em 14 de setembro de 2026

311 tokens totais	US\$ 0,0001292 por chamada	US\$ 0,1292 por 1.000 chamadas
-----------------------------	--------------------------------------	--

1. Feature implementada

Na tela **Nova despesa**, o usuário descreve uma compra em linguagem natural. Exemplo validado: *“Gabi pagou 150 reais no jantar para todos”*.

O backend envia o texto e o contexto do grupo ao modelo **gpt-5.6-luna**. A resposta estruturada sugere descrição, valor, categoria, pagador, participantes e uma explicação. O formulário é preenchido automaticamente, mas permanece aberto para revisão antes do salvamento.

2. Resposta real validada

Campo	Sugestão da IA
Descrição	Jantar
Valor	R\$ 150,00
Categoria	Restaurante
Pagador	Gabi
Participantes	Todos os 5 participantes do grupo
Explicação	Gabi pagou o jantar de 150 reais, dividido entre todos.

3. Cálculo de custos

Preços utilizados: **US\$ 0,20 por 1 milhão de tokens de entrada** e **US\$ 1,20 por 1 milhão de tokens de saída**.

Componente	Tokens	Fórmula	Custo
Entrada	244	$244 \times 0,20 \div 1.000.000$	US\$ 0,0000488
Saída	67	$67 \times 1,20 \div 1.000.000$	US\$ 0,0000804
Total	311	entrada + saída	US\$ 0,0001292
1.000 chamadas	311.000	$0,0001292 \times 1.000$	US\$ 0,1292

4. Cache e economia

Antes da chamada, o backend calcula um hash SHA-256 com grupo, prompt normalizado, participantes e modelo. Se já existir uma resposta igual no PostgreSQL, ela é devolvida sem nova chamada à OpenAI.

No teste, a primeira requisição retornou **cached: false**. A segunda, com o mesmo texto, retornou **cached: true** e registrou economia acumulada de **US\$ 0,0001292**.

Cenário com 1.000 pedidos idênticos	Valor
Sem cache: 1.000 chamadas pagas	US\$ 0,1292
Com cache: 1 chamada paga + 999 respostas reutilizadas	US\$ 0,0001292
Economia estimada	US\$ 0,1290708 (99,9%)

5. Arquitetura e segurança

A chave da OpenAI permanece exclusivamente no backend, armazenada em Secrets. O frontend conversa apenas com a API do Split. As respostas e métricas de uso são guardadas no banco para auditoria da estimativa e reutilização segura.

A implementação foi validada com chamada real, repetição via cache, typecheck completo e revisão visual em viewport mobile.